

REPORTE DE IMPLEMENTACIÓN Y EXPERIMENTOS

Seguro Agrícola Indexado para Café — Quindío y Nariño

Fase 2 · Entregable de la semana 5

Equipo 9: Diego Alejandro Lemus · Manuel Lindarte · Jaime Arturo Ramírez · Israel Valenzuela

Alcance del informe

Componente analítico del artefacto: calibración del índice climático y scoring, es decir, el modelo predictivo de rendimiento que sustenta la señal de exposición.

Fuera de alcance: pricing, trigger de pago y medición actuarial (prima, efectividad de cobertura, riesgo base), conforme al alcance declarado en la Fase 1.

Contenido

Resumen

1. Respuesta de los análisis a los requerimientos y su integración — *Criterio 1*
2. Alternativas de modelos y plan de pruebas — *Criterio 2*
3. Tratamiento previo de los datos y verificación de supuestos — *Criterio 3*
4. Entrenamiento, validación y calibración de parámetros — *Criterio 4*
5. Análisis de resultados, selección de alternativas y ajustes — *Criterio 5*
6. Componentes pendientes y plan hacia el prototipo funcional — *Criterio 6*
7. Conclusiones

Referencias

Anexo A. Registro de actividades del notebook

Resumen

El informe documenta la implementación y los procesos de la Fase 2 del proyecto, cuyo objetivo es llevar el componente analítico del artefacto —la señal de exposición climática BAJO / MEDIO / ALTO para el analista de suscripción— desde la especificación de la Fase 1 hasta una selección de variables, modelos, métricas e hiperparámetros con evidencias. El trabajo se ejecutó como un análisis del desarrollo previo seguido de una ronda experimental completa, consignada en el notebook Entrega_2.ipynb. Los principales resultados son:

- **El panel analítico fue revisado:** se depuró a 24 observaciones (12 años × 2 departamentos, 2007–2018), sin duplicados ni valores faltantes. Se excluyeron cuatro variables con fuga de la variable objetivo: producción, área cosechada, porcentaje de área cosechada y la anomalía de temperatura construida con información futura.
- **El índice SPI-3 fue validado.** La agregación ponderada original del panel es consistente: su correlación con un promedio simple corregido es 0,967 en Nariño y 1,000 en Quindío, y la distribución del índice revisado presenta media ≈ 0 y desviación $\approx 1,00$, propiedades esperadas de un SPI estandarizado.
- **Se seleccionó la especificación fenológica de seis variables** —SPI-3 de floración, desarrollo y cosecha, temperatura máxima, ONI y el indicador de roya— por su equilibrio entre desempeño, parsimonia e interpretabilidad, evaluada con Ridge de parámetro fijo bajo Leave-One-Year-Out.
- **La comparación final de modelos no respalda un modelo único para ambos departamentos.** Se seleccionó ExtraTrees para Nariño (RMSE 100,1 kg/ha; R^2 0,114; mejora de 13,7 % frente al baseline de la media histórica) y Random Forest para Quindío (RMSE 90,5 kg/ha; R^2 0,326; mejora de 24,7 %). Ambos cumplen con holgura los umbrales de error comprometidos en la Fase 1 (RMSE $\leq$ 186 kg/ha; MAE $\leq$ 149 kg/ha), con errores equivalentes al 6–9 % del rendimiento medio

departamental, si bien el R^2 LOYO queda por debajo del rango deseado de 0,50, lo que se reporta como diagnóstico del panel productivo y se discute en la sección 5.5.

- **La interpretabilidad (SHAP) y la sensibilidad delimitan el alcance de lo explicable por clima.** Roya y SPI-3 de floración dominan la importancia en ambos departamentos —las tres primeras variables concentran 82,0 % y 86,1 % de la importancia SHAP— y al eliminar el indicador de roya el RMSE LOYO se deteriora entre 7 % y 32 %. Como la variable ficticia de roya identifica retrospectivamente la epidemia 2012–2014, su papel en un scoring prospectivo queda definido como decisión de la Fase 3.
- **El GAM comprometido en la Fase 1 (D1) se ejecutó y se declaró exploratorio:** sobre las 14 observaciones con información satelital real (2012–2018) alcanzó un pseudo- R^2 de 0,225 sin términos suaves significativos y un R^2 LOYO de $-2,73$; la evidencia disponible no sustenta curvas de respuesta no lineales y la no linealidad es capturada por los modelos de árboles.

El informe se organiza siguiendo los seis criterios de la rúbrica del entregable de la semana 5. Los valores numéricos de las tablas se reproducen de las salidas del notebook `Entrega_2.ipynb`; los porcentajes derivados, como la mejora frente al baseline, se indican como cálculos sobre esas salidas.

1. Respuesta de los análisis a los requerimientos y su integración (Criterio 1)

1.1 El artefacto, el alcance y el problema que se resuelve

El artefacto es un panel de evaluación climática que produce una señal de exposición BAJO / MEDIO / ALTO para apoyar la evaluación técnica del riesgo por parte del analista de suscripción de un seguro agrícola indexado para pequeños caficultores de Quindío y Nariño. Según el alcance formal de la Fase 1, el artefacto no calcula la prima, no define un trigger de pago ni estima efectividad de cobertura: el analista conserva la decisión de pricing y recibe la lectura de exposición como insumo. En coherencia, el alcance de esta Fase 2 llega hasta el scoring —la calibración del índice y el modelo predictivo que dan sustento cuantitativo a la señal— que la Fase 3 integrará al prototipo funcional de una pantalla (Configurar – Observar – Valorar).

La pregunta de negocio que responden los análisis de esta fase es doble:

- **Descriptiva (Track A):** ¿qué condiciones climáticas —sequía o exceso de lluvia, medidas con SPI-3— diferencian el riesgo entre departamentos y cuán confiable es el índice que las mide?
- **Predictiva (Track B):** dado un estado climático y fitosanitario, ¿qué rendimiento en kg/ha es esperable y con qué error, para que la señal y, en su momento, la estimación de pérdida tengan sustento cuantitativo?

Ambas preguntas responden a los requerimientos de desempeño D1–D4 y de negocio N2–N3 comprometidos en la Fase 1, y sus resultados son el insumo analítico de los requerimientos funcionales F1–F8 y de validación N1, N4 y N5, que se prueban en la Fase 3 sobre el prototipo.

1.2 Requerimientos de la Fase 1

La tabla siguiente reproduce los requerimientos comprometidos (N1–N5, D1–D6, F1–F8) con su prueba y criterio de evaluación, tal como quedaron formalizados en la primera entrega. Es la lista de chequeo contra la cual se evaluará el prototipo en la Fase 3 y el marco de coherencia de los experimentos de esta Fase 2.

ID	Requerimiento (resumen)	Prueba prevista	Criterio / métrica	Rango deseado
N1	Señal de exposición explicable para el analista de suscripción	Demo guiada + cuestionario de 5 preguntas (2 usuarios)	% respuestas correctas; explicación sin ayuda	≥ 80 %
N2	Concordancia señal ↔ caídas observadas de rendimiento	Cruzar clasificación vs. pares depto–año bajo el P25 de rendimiento	Recall; falsas alarmas	Recall ≥ 60 %; FA ≤ 30 %
N3	Umbral diferenciados por departamento	Calibrar percentiles SPI-3 por departamento (ERA5)	Diferencia y sentido de los umbrales	Distintos y explicables por perfil climático
N4	Validación histórica sobre eventos conocidos	Señal sobre serie histórica vs. cronología ENSO/sequías	Eventos severos detectados por depto	Detección en ambos departamentos
N5	Cobertura y comparabilidad Quindío–Nariño	Complejidad del panel por depto y variable	% completitud	≥ 90 % por variable
D1	Relaciones no lineales mediante GAM	GAM por depto (SPI-3, Tmax, NDVI); significancia y forma de curvas	Curvas estimadas; términos significativos	≥ 3 variables; ≥ 2 con $p < 0,05$
D2	Explicabilidad XGBoost + SHAP	Importancia SHAP global y dependencias parciales	Top-3 ≥ 60 % de importancia; coherencia con D1	SPI-3, NDVI o Tmax entre las 3 principales
D3	Precisión de la estimación de rendimiento	Out-of-time + LOYO; RMSE/MAE en kg/ha y % del rango	RMSE; MAE; R^2 como diagnóstico	RMSE ≤ 186; MAE ≤ 149; R^2 ≥ 0,50
D4	Estabilidad temporal (controlando roya/renovación)	Comparar subperiodos con y sin años de roya	ΔR^2 entre subperiodos	$ \Delta R^2 < 0,15$
D5	Robustez de la clasificación	Perturbar entradas ±5 % y reclasificar	% de reclasificaciones	≤ 10 %
D6	Validación de la señal contra anomalía de NDVI (validación primaria a nivel de celda)	Anomalía NDVI por celda—compuesto MODIS vs. señal	Spearman; recall sobre anomalía severa	ρ ≥ 0,50; recall ≥ 60 %

ID	Requerimiento (resumen)	Prueba prevista	Criterio / métrica	Rango deseado
F1	Panel de una sola pantalla	Recorrido guiado	Cambios de pantalla; tiempo	0 cambios; < 5 min
F2	Sección Configurar funcional	Prueba de selectores y persistencia	Combinaciones correctas	100 %
F3	Sección Observar funcional	Demo con usuario técnico	Tiempo por métrica; completitud	< 1 min; todas visibles
F4	Sección Valorar funcional	3 casos justificados por el usuario	Casos justificados	3 de 3
F5	Reproducibilidad del pipeline	Dos ejecuciones independientes	Datasets idénticos	100 % idénticos
F6	Trazabilidad documental (IFRS S2)	Auditoría externa contra checklist de 4 ítems	Checklist	4 de 4
F7	Herramientas abiertas y fuentes públicas	Revisión de requirements y fuentes	Licencias; accesibilidad	Ninguna comercial; todas públicas
F8	Consulta por ubicación y riesgo de base espacial	Consultas centroide / borde / fuera de cobertura	Asignación de celda; distancia al centroide	100 %; distancia $\leq$ radio de celda

1.3 Cómo se integran los modelos para cumplir los requerimientos

El esquema de solución es de dos ejes complementarios, alineado con la arquitectura estándar de validación de seguros indexados (CEPAL/GIZ, 2022):

- **Eje descriptivo (Track A) — el índice como base de la señal.** El SPI-3 (McKee et al., 1993) se calcula sobre precipitación ERA5-Land agregada a nivel departamental y resume, en ventanas fenológicas del cultivo (floración, desarrollo de grano y cosecha), si el periodo fue más seco o más húmedo de lo normal. Sobre este índice se calibran, por departamento, los umbrales que separan los niveles de la señal. En esta fase el Track A se concentró en auditar y validar la construcción del índice (secciones 3.1 y 3.2).
- **Eje predictivo (Track B) — el scoring que dimensiona la pérdida.** Los modelos de rendimiento estiman la magnitud esperada del impacto productivo dado el estado climático y fitosanitario. Este scoring es el que permite que la señal no sea solo una lectura de anomalía, sino una lectura calibrada contra caídas observadas de rendimiento (N2) y con un error conocido (D3).


Correspondencia con las capas analíticas. El esquema de dos ejes se corresponde con las tres capas del artefacto. La capa descriptiva la constituyen los indicadores derivados —SPI-1 y SPI-3 por ventana fenológica, anomalía de NDVI y tablas de completitud— que convierten las series en bruto en afirmaciones interpretables sobre qué ocurrió. La capa predictiva es el scoring del Track B: los modelos que estiman el rendimiento y cuantifican qué variables lo explican. La capa prescriptiva es la señal BAJO / MEDIO / ALTO y los umbrales calibrados por departamento, que traducen el diagnóstico en una lectura accionable y constituyen el producto que el artefacto entrega.

La integración es un encadenamiento y no una yuxtaposición: la capa descriptiva construye los indicadores sin los cuales las otras dos no tendrían insumo; la predictiva localiza en qué rangos el rendimiento se deteriora, que es lo que evita que los cortes de la señal se fijen de forma arbitraria; y la prescriptiva convierte esos cortes en un nivel de exposición acompañado de las variables responsables. El circuito se cierra con la validación: los requerimientos D6 y N2 contrastan la salida prescriptiva contra productos de la capa descriptiva —anomalía de NDVI y rendimiento observado— de modo que lo que la solución afirma se comprueba contra lo que ella misma describió al comienzo.

Alcance de la capa prescriptiva. El artefacto sí produce una prescripción: el nivel de exposición y su justificación. Lo que permanece fuera de su alcance es la decisión de suscripción y el pricing, que corresponden al analista. La capa prescriptiva del artefacto termina en la lectura de riesgo; la decisión comercial empieza donde el artefacto termina.

Integración de las capas descriptiva, predictiva y prescriptiva

Cada capa consume la salida de la anterior. La validación devuelve el circuito a la capa descriptiva.



Equipo 9 · Entregable 2 · Criterio 1 — coherencia entre requerimientos, modelos y capas

Figura 1. Arquitectura analítica del artefacto: encadenamiento de las capas descriptiva, predictiva y prescriptiva, y circuito de validación.

Esta integración hace explícito el encadenamiento de requerimientos: el índice corregido (N3, Track A) alimenta los predictores fenológicos del scoring (D3, Track B); la interpretabilidad del scoring (D2) es lo que hace explicable la señal (N1, F4); y la estabilidad temporal del scoring frente al choque de roya (D4) define qué puede prometerse al usuario en producción (N2).

1.4 Estado de cumplimiento tras la Fase 2

La auditoría del desarrollo previo encontró que el repositorio técnico reportaba 8 requerimientos con numeración propia y significados distintos a los 19 comprometidos, además de tres problemas de fondo: panel con duplicados, variables con fuga de la variable objetivo y un SPI-3 cuyos percentiles no correspondían a un índice estandarizado. El notebook de esta Fase 2 ejecutó las verificaciones y experimentos que resuelven esas objeciones. La trazabilidad requerimiento → evidencia es:

ID	Evidencia producida en la Fase 2	Estado tras la Fase 2
N1	SHAP e importancia por modelo final documentados (5.2), listos para la justificación visual del panel	Evidencia analítica lista; prueba con usuarios en Fase 3
N2	Scoring por departamento con error conocido y validación temporal (4.4 y 5.1)	Evidencia analítica lista; prueba de cruce con P25 en Fase 3
N3	SPI-3 auditado y validado: distribución estandarizada y agregación robusta; base para recalibrar umbrales	Parcial: índice validado; umbrales se recalculan con el índice corregido en Fase 3
N4	Serie SPI-3 2000–2024 revisada, disponible para la validación histórica de la señal	Pendiente Fase 3 (prueba sobre el prototipo)
N5	Completitud verificada: panel sin nullos ni duplicados; cobertura EVA municipal documentada (2007–2018)	Cumplido para el panel productivo; completitud del panel espacial en Fase 3
D1	GAM implementado y evaluado (pseudo- R^2 0,225; LOYO R^2 -2,73; sin términos significativos en 14 obs)	Ajuste de alcance declarado: GAM queda como herramienta exploratoria; la no linealidad la capturan los árboles (5.4)
D2	XGBoost entrenado como contraste + SHAP sobre los modelos finales; top-3 concentra 82,0 % (Nariño) y 86,1 % (Quindío); SPI-3 de floración en segunda posición en ambos	Cumplido: la concentración supera el umbral de 60 % y una variable climática figura entre las tres principales en ambos departamentos. Se observa que la variable dominante es el indicador fitosanitario, cuya implicación se analiza en 5.3
D3	RMSE y MAE LOYO de los modelos seleccionados: Nariño 100,1 / 86,1; Quindío 90,5 / 70,4 kg/ha	Cumplido en RMSE y MAE con holgura; R^2 diagnóstico (0,114 y 0,326) por debajo del rango deseado de 0,50, discutido en 5.5
D4	Sensibilidad con y sin roya ejecutada: ΔR^2 LOYO $\approx$ 0,47 (Nariño) y 0,49 (Quindío) al retirar la variable	No cumple el umbral $ \Delta R^2 < 0,15$; se documenta como limitación estructural y define un pendiente de diseño para la Fase 3 (sección 6)

ID	Evidencia producida en la Fase 2	Estado tras la Fase 2
D5	Requiere la señal implementada	Pendiente Fase 3 (prueba sobre el prototipo)
D6	Cobertura MODIS auditada y corregida (2012–2019, sin interpolación hacia atrás); panel satelital de 14 obs construido	Evidencia parcial; la validación celda–compuesto requiere el panel espacial (Fase 3)
F1–F8	Requieren prototipo	Pendiente Fase 3; el plan de la sección 6 las calendariza

Dos principios rigen esta tabla. Primero, ningún requerimiento desaparece: los ajustes (D1, N3, D4) se declaran con su justificación y su impacto en el esquema (sección 5.4). Segundo, la Fase 2 entrega la evidencia analítica de los requerimientos de desempeño y deja a la Fase 3 las pruebas sobre el prototipo (N1, N2, N4, N5, D5, D6, F1–F8), que es donde la rúbrica del curso las evalúa.

2. Alternativas de modelos y plan de pruebas (Criterio 2)

2.1 Alternativas consideradas por requerimiento

Para el requerimiento predictivo (D3 y soporte de N2) se plantearon cinco familias de modelos más dos referencias, y para el requerimiento de relaciones no lineales (D1) se planteó un GAM adicional. La tabla resume ventajas, desventajas y el papel de cada alternativa en el plan de pruebas, considerando la restricción central del problema: un panel productivo de 24 observaciones que obliga a validación temporal estricta y a preferir métodos de baja varianza.

Alternativa	Familia	Ventajas para este problema	Desventajas / riesgos	Papel en el plan de pruebas
Baseline: media histórica	Referencia	Costo cero; referencia real del asegurador (años normales)	No usa clima; R^2 LOYO $\approx -0,19$ por construcción del panel corto	Umbral de utilidad: un modelo solo se justifica si lo supera
Ridge (L2)	Lineal regularizada	Estable ante multicolinealidad extrema; pocos parámetros	Supone linealidad; sin interacciones explícitas subajusta	Comparador inicial de especificaciones y referente lineal
Lasso (L1)	Lineal regularizada	Selección automática de variables	Muy sensible con $n = 12$ por departamento; coeficientes inestables	Evaluado y descartado antes de parametrización
Random Forest	Ensamble (bagging)	Captura no linealidades e interacciones; robusto (Breiman, 2001)	Puede sobreajustar con n pequeño; más varianza que ExtraTrees	Candidato a selección; parametrización anidada
ExtraTrees	Ensamble (splits aleatorios)	Menor varianza en muestras pequeñas (Geurts et al., 2006)	Menos interpretable individualmente; se interpreta con SHAP	Candidato principal
XGBoost	Ensamble (boosting)	Comprometido en la Fase 1 (D2); potencia en datos tabulares	Muchos hiperparámetros; alto riesgo de sobreajuste con n pequeño	Modelo de contraste para interpretabilidad
GAM	Aditivo generalizado	Curvas de respuesta suaves interpretables (D1)	Necesita más datos: solo 14 obs con MODIS real	Exploratorio: caracterización funcional, no predicción

2.2 Montaje experimental

El montaje responde a tres decisiones, todas orientadas a no usar información futura:

- **Validación Leave-One-Year-Out (LOYO) por departamento.** Para cada departamento se entrena con 11 años y se prueba con el año dejado fuera, rotando sobre 12 pliegues (2007–2018). El LOYO es el esquema recomendado para series temporales cortas: la validación cruzada aleatoria produce fuga de información futura y sobreestima el R^2 de generalización (Bergmeir y Benítez, 2012). La unidad de exclusión es el año completo.
- **Parametrización anidada dentro del LOYO.** La búsqueda de hiperparámetros se ejecuta dentro de cada pliegue, con TimeSeriesSplit sobre los años de entrenamiento (Cawley y Talbot, 2010). Así, los parámetros de cada año de prueba se eligen sin ver ese año, y el RMSE LOYO reportado corresponde a un proceso completo —entrenar, parametrizar, predecir— sin fuga.
- **Separación de la decisión de variables y de la decisión de algoritmo.** La selección de la especificación se hizo primero con Ridge de parámetro fijo ($\alpha = 1$), de modo que la elección de variables no quedara contaminada por la parametrización de un algoritmo particular; solo después se compararon familias sobre la especificación elegida.

Como referencia adicional del diseño, el hold-out temporal 2017–2018 del desarrollo previo fue auditado: contiene 4 observaciones (2 años $\times$ 2 departamentos), un tamaño que no permite conclusiones estables. Por ello los experimentos de esta fase reportan LOYO completo (24 predicciones año a año) y no un hold-out de 4 puntos.

2.3 Métricas de desempeño y su justificación

Métrica	Justificación en el contexto	Umbral de referencia
RMSE (kg/ha)	Penaliza cuadráticamente los errores grandes: en un seguro indexado, subestimar una pérdida severa es el error más costoso. Unidad de negocio directa	≤ 186 kg/ha (D3, Fase 1)
MAE (kg/ha)	Error medio interpretable para comunicación con el analista; complementa al RMSE	≤ 149 kg/ha (D3, Fase 1)
R ² LOYO	Capacidad explicativa fuera de muestra; se reporta como diagnóstico interno del panel productivo, no como evidencia de generalización	$\geq 0,50$ (rango deseado)
Mejora vs. baseline (%)	Variación porcentual del RMSE frente a la media histórica del entrenamiento; traduce el aporte del modelo en términos del negocio	> 0 % (superar al baseline)
Estabilidad del error	El error del peor año y su dispersión: relevante porque el scoring alimenta decisiones por periodo	Reporte por modelo
pseudo-R ² , AIC, EDoF (GAM)	Comparación de modelos aditivos con términos suaves	Reporte exploratorio
Concordancia de rankings SHAP	Estabilidad de la interpretación entre familias de modelos (D2)	Reporte con p-valor

Las métricas de clasificación de la señal (recall, falsas alarmas, robustez D5) se aplican en la Fase 3, cuando la señal esté implementada sobre el prototipo; los umbrales ya están definidos en la sección 1.2.

2.4 Otras decisiones de diseño y sus alternativas

La elección de la familia de modelos no es la única decisión con alternativas evaluadas. La tabla siguiente recoge las restantes, con la alternativa adoptada, las descartadas y el requerimiento que pone a prueba cada decisión.

Decisión	Adoptada	Alternativas descartadas y por qué	Razón de la elección	Requerimiento que la prueba
Fuente de datos climáticos	ERA5-Land, con IDEAM como contraste	Solo estaciones IDEAM: cobertura desigual y series con huecos. CHIRPS: mejor resolución pero solo precipitación, obligaría a conciliar dos mallas. TerraClimate: resolución mensual, insuficiente	Malla completa y homogénea, comparable entre departamentos	N5
Índice de condición hídrica	SPI-1 y SPI-3 por ventana fenológica	Precipitación en bruto: no comparable entre zonas con perfiles de lluvia distintos. SPEI: requiere estimar evapotranspiración, agregando supuestos. Componentes principales: el índice resultante carece de lectura física y contradice el requerimiento de explicabilidad	Estandarizado y comparable entre departamentos; definición establecida; solo requiere precipitación	N3, D3
Arquitectura de datos	Dos paneles complementarios	Solo panel productivo: sin resolución espacial, no permite validación independiente ni consulta por finca. Solo panel espacial: sin variable de pérdida, la señal no se conectaría con el resultado económico	Cada panel hace aquello para lo que su tamaño alcanza: el espacial valida, el productivo diagnostica	D6; D3 y N2
Método de explicabilidad	SHAP sobre los modelos finales	Coeficientes lineales: la familia lineal quedó descartada por desempeño. Importancia por permutación: con variables correlacionadas, permutar una permite que su correlacionada compense y el reparto se vuelve poco confiable	Entrega contribución por observación y global, y permite justificar un caso concreto ante el analista	D2, N1
Estrategia de validación	LOYO con parametrización anidada	Hold-out simple: con este panel deja 2 observaciones por departamento. K-fold aleatorio: mezcla años y produce fuga temporal	Respetar la estructura temporal y su dispersión entre pliegues informa sobre estabilidad	D3, D4

Nota sobre el carácter de estas decisiones. Todas fueron adoptadas en la Fase 1 y la Fase 2 las sometió a verificación empírica. Dos resultaron modificadas por la evidencia y así se declara en la sección 5.4: el GAM pasó a herramienta exploratoria y la validación primaria de la señal se traslada al panel espacial en la Fase 3.

3. Tratamiento previo de los datos y verificación de supuestos (Criterio 3)

Esta fase comenzó por verificar qué había realmente en el panel que alimentaba al modelo del desarrollo previo. La auditoría encontró y corrigió cuatro problemas de fondo que condicionan todo lo demás.

3.1 Auditoría del ETL y correcciones aplicadas

Verificación	Resultado en el desarrollo previo	Corrección aplicada en la Fase 2
Duplicados del panel	El archivo de features tenía 40 filas para 24 combinaciones únicas departamento-año: cada año aparecía duplicado por celda climática	Panel depurado a 24 observaciones únicas, 0 duplicados y 0 faltantes (2007–2018; 12 años × 2 departamentos)
Fuga de la variable objetivo	El rendimiento (producción ÷ área cosechada) convivía con sus componentes: producción, área cosechada y porcentaje de área cosechada, esta última la variable más importante del modelo previo en Quindío	Se excluyen del conjunto de predictores todas las variables con relación mecánica con el rendimiento
Temperatura construida con información futura	La anomalía de temperatura tomaba el promedio del año completo, incluidos los meses posteriores a la cosecha	Variable excluida del conjunto de predictores
Variables satelitales con valores artificiales	NDVI y EVI aparecían constantes antes de 2012: la interpolación bidireccional propagó el valor de 2012 hacia atrás hasta 2007	El panel principal 2007–2018 se modela sin NDVI ni EVI; se construye un panel satelital de 14 observaciones (2012–2018) con observaciones MODIS reales
Reconstrucción del rendimiento	—	Rendimiento recalculado como producción × 1000 / área cosechada: diferencias del orden de 10^{-13} , error de precisión numérica, de modo que el objetivo del modelo está bien construido

Resultado de la auditoría del panel: Tras eliminar los registros duplicados, corregir la fuga de información, reconstruir la variable objetivo y generar las variables derivadas, el panel consolidado quedó conformado por 24 observaciones y 45 variables. Posteriormente, para los experimentos predictivos principales, se excluyeron las seis variables satelitales NDVI/EVI debido a que su cobertura observada solo estaba disponible entre 2012 y 2019, obteniéndose un panel principal de modelado de 24 observaciones y 39 variables, utilizado en todos los experimentos de selección, parametrización y validación de modelos.

3.2 Validación del índice climático SPI-3

El SPI-3 es la materia prima del eje descriptivo y provee tres de las seis variables de la especificación seleccionada. Su construcción fue auditada por partida doble:

- **Método de agregación espacial.** Se comparó la ponderación original del pipeline contra un promedio simple corregido de las celdas ERA5-Land por departamento. La correlación entre ambas alternativas es 0,967 en Nariño y 1,000 en Quindío —en Quindío el departamento coincide con una única celda efectiva— y las diferencias mensuales promedio son cercanas a cero. La agregación original es robusta.
- **Propiedades estadísticas del índice.** El SPI-3 revisado (2000–2024, por departamento) presenta media cercana a cero y desviación de 1,00 — $\sigma = 1,0014$ en ambos departamentos— y percentiles P10 y P90 entre $-1,21 / -1,09$ y $+1,39 / +1,52$, consistentes con un índice estandarizado cuyos umbrales teóricos son $\pm 1,28$. El desarrollo previo reportaba percentiles incompatibles con un índice estandarizado, incluido un P90 negativo en Quindío; el SPI-3 corregido restaura las propiedades del índice y es la base para recalibrar los umbrales departamentales de la señal (N3) en la Fase 3.
- **Consistencia temporal y de fuentes.** El panel final no tiene faltantes, las series de ERA5-Land, EVA y ONI cubren 2007–2018 de forma consistente, y los rezagos usados se restringen a información disponible antes del año a estimar.

3.3 Tratamiento previo según el tipo de datos

- **Variables continuas estandarizadas por construcción:** SPI-3 y ONI son índices adimensionales con media 0 y varianza cercana a 1 por diseño; no requieren re-escalamiento para los modelos de árboles. Para los modelos lineales el pipeline estandariza los predictores.
- **Variables continuas en unidades físicas:** temperatura máxima anual en grados Celsius, usada directamente por los árboles, cuyos cortes son invariantes a transformaciones monótonas.
- **Variables binarias:** indicador de roya, con valor 1 en el periodo epidémico 2012–2014.

- **Ventanas fenológicas:** el SPI-3 se agrega en las ventanas de floración, desarrollo y cosecha del ciclo cafetero para construir predictores con sentido agronómico, dado que la humedad en floración afecta el amarre de grano de forma distinta a la humedad en cosecha.
- **Tratamiento por familia de modelos:** los modelos lineales exigen predictores sin colinealidad extrema y relaciones lineales; al verificarse empíricamente su subdesempeño, la decisión se inclinó hacia los árboles, que no requieren supuestos de distribución ni de forma funcional.

3.4 Verificación de los supuestos de los modelos

La Fase 1 comprometió pruebas de supuestos sobre los modelos elegidos. La verificación se realizó sobre la especificación lineal regularizada del desarrollo previo, con los siguientes resultados por departamento. Multicolinealidad: el factor de inflación de la varianza medio alcanzó 1.641 en Nariño y 3.387 en Quindío, frente a un umbral convencional de alarma de 10, lo que indica colinealidad extrema entre predictores. Autocorrelación de residuos: el estadístico de Durbin-Watson resultó de 0,372 en Nariño y 0,566 en Quindío; en ausencia de autocorrelación el estadístico se sitúa alrededor de 2, de modo que ambos valores indican autocorrelación positiva de primer orden, atribuible al conglomerado temporal de la crisis fitosanitaria de 2012–2014. Capacidad de generalización: el coeficiente de determinación en validación temporal resultó negativo en Nariño ($-0,581$), pese a un ajuste satisfactorio dentro de muestra.

Estos tres resultados se leen en conjunto: los supuestos de los modelos lineales no se sostienen sobre este panel, y la regularización Ridge, aunque mitiga el efecto de la colinealidad sobre la predicción, no corrige la autocorrelación ni la inestabilidad temporal. Declararlos violados y documentar la mitigación es metodológicamente más sólido que reportarlos como cumplidos, y es lo que motivó reorientar la selección hacia familias que no dependen de esos supuestos.

Esta evidencia tiene tres consecuencias metodológicas, todas aplicadas en la Fase 2:

- **Los modelos seleccionados en esta fase, ensambles de árboles, no dependen de esos supuestos:** no hay forma funcional lineal que verificar, ni supuestos de normalidad u homocedasticidad de residuos, lo que elimina la exposición del diseño a las violaciones detectadas.
- **Los supuestos que sí aplican a los árboles se verificaron por diseño:** ausencia de fuga temporal, garantizada por el LOYO por año completo y la parametrización anidada; ausencia de fuga mecánica de la variable objetivo, garantizada por la exclusión documentada en 3.1; y representatividad de la muestra, acotada por el tamaño del panel y declarada como limitación en 5.5.
- **La verificación de la relación lineal frente a la no lineal se hizo empíricamente y por partida doble:** los modelos lineales regularizados no superan el baseline LOYO, mientras que los árboles sí lo superan, evidencia de no linealidades e interacciones que los lineales no capturan; y el GAM exploratorio no encontró términos suaves significativos en la submuestra de 14 observaciones, lo que se interpreta como limitación de potencia estadística del panel y no como evidencia de linealidad (sección 4.5).

3.5 Verificación de supuestos sobre los datos binarios y la temporalidad

- **Variable binaria (roya):** se verificó su papel mediante un análisis de sensibilidad completo, entrenando con y sin la variable (sección 5.3), única forma de cuantificar cuánto del desempeño depende de ella.
- **Supuesto de no fuga temporal:** garantizado por diseño mediante LOYO por año completo, parametrización anidada con TimeSeriesSplit, exclusión de variables contemporáneas mecánicas y restricción de rezagos a información disponible antes del año a estimar.

4. Entrenamiento, validación y calibración de parámetros (Criterio 4)

4.1 Selección de variables: comparación de especificaciones

Tres especificaciones de predictores se compararon con Ridge de parámetro fijo ($\alpha = 1$) bajo LOYO, para separar la decisión de variables de la decisión de algoritmo:

Especificación	Variables	Nariño RMSE (kg/ha)	Quindío RMSE (kg/ha)
Mínima	SPI-3 medio, temperatura máxima, ONI	149,9	118,8
Fenológica	SPI-3 floración, SPI-3 desarrollo, SPI-3 cosecha, temperatura máxima, ONI, roya	131,2	108,2
Ampliada	10 variables climáticas y fitosanitarias	150,8	107,1
Baseline (media histórica del entrenamiento)	—	116,0	120,2


Lectura: en Nariño ninguna especificación supera el baseline, y la diferencia entre la fenológica y la ampliada es de unos 20 kg/ha con cuatro variables menos en la primera; en Quindío la ampliada y la fenológica superan al baseline por unos 12 kg/ha, con apenas 1 kg/ha de diferencia entre ellas. Se selecciona la especificación fenológica por desempeño comparable, mayor parsimonia, estabilidad entre departamentos e interpretabilidad agronómica, decisión provisional que la comparación de familias reevalúa. Los R^2 negativos de esta ronda, especialmente en Nariño, se conservan como evidencia de la dificultad de generalizar con un panel de 12 años.

4.2 Comparación inicial de familias de modelos

Sobre la especificación fenológica, cinco familias se compararon con LOYO, con las mismas variables y las mismas observaciones. Resultados iniciales, sin parametrización:

Depto.	Modelo	RMSE (kg/ha)	MAE (kg/ha)	R^2 LOYO	Mejora vs. baseline (%)
Nariño	ExtraTrees	101,8	80,2	0,08	+12,3
Nariño	Baseline (media histórica)	116,0	87,5	-0,19	0,0
Nariño	Random Forest	116,5	94,4	-0,20	-0,4
Nariño	XGBoost	122,3	98,5	-0,32	-5,4
Nariño	Ridge	131,2	116,4	-0,52	-13,1
Nariño	Lasso	150,4	137,5	-1,00	-29,6
Quindío	ExtraTrees	87,7	66,9	0,37	+27,0
Quindío	Random Forest	98,9	72,5	0,20	+17,8
Quindío	XGBoost	102,1	81,1	0,14	+15,0
Quindío	Ridge	108,3	97,4	0,04	+10,0
Quindío	Baseline (media histórica)	120,2	98,5	-0,19	0,0
Quindío	Lasso	130,1	113,3	-0,39	-8,3

Comparación de familias de modelos — validación Leave-One-Year-Out



Verde: el modelo reduce el error frente a la media histórica del entrenamiento. Rojo: no la supera. Especificación fenológica de 6 variables, sin parametrización.

Figura 2. Comparación de familias de modelos bajo validación Leave-One-Year-Out. En verde, los modelos que reducen el error frente a la media histórica del entrenamiento.

Lectura. En Nariño solo ExtraTrees supera la referencia de la media histórica: reduce el RMSE en 12,3 %, mientras que Random Forest empatiza y las tres familias restantes quedan por encima del baseline, con Lasso muy por detrás (150,4 kg/ha frente a 116,0). En Quindío el panorama es más favorable: cuatro de las cinco familias superan la referencia, encabezadas por ExtraTrees con una reducción del 27,0 %, y solo Lasso queda por debajo. Este contraste entre departamentos es el primer indicio de que un modelo único para ambos no es la mejor opción, decisión que la parametrización anidada confirma.

Decisión de esta ronda: ExtraTrees pasa a parametrización como candidato principal; Random Forest y XGBoost continúan como alternativas de ensamble, este último por el compromiso D2 de la Fase 1; Ridge se conserva como referencia regularizada; Lasso se descarta por quedar por debajo del baseline en ambos departamentos.

4.3 Parametrización anidada

Los tres modelos de árboles pasaron a una búsqueda de hiperparámetros anidada dentro del LOYO: en cada pliegue, la selección se hace con TimeSeriesSplit sobre los 11 años de entrenamiento y el año dejado fuera se predice con los parámetros elegidos. Se optimizaron profundidad máxima, número de árboles, mínimo de hojas, fracción de variables por división y, para XGBoost, tasa de aprendizaje y regularización. La parametrización no produjo mejoras homogéneas entre departamentos, lo que anticipa la decisión final:

Depto.	Modelo	RMSE inicial → final (kg/ha)	R ² inicial → final
Nariño	ExtraTrees	101,8 → 100,1	0,084 → 0,114
Nariño	Random Forest	116,5 → 120,6	-0,201 → -0,287
Nariño	XGBoost	122,3 → 135,2	-0,323 → -0,617
Quindío	Random Forest	98,9 → 90,5	0,195 → 0,326
Quindío	ExtraTrees	87,7 → 96,5	0,366 → 0,233
Quindío	XGBoost	102,1 → 103,0	0,141 → 0,126

Los modelos ExtraTrees en Nariño y Random Forest en Quindío resultaron estables frente a alternativas cercanas del grid, mientras que XGBoost tendió a configuraciones más complejas que no generalizan: su RMSE empeora tras parametrizar en ambos departamentos. Con $n = 12$ por departamento, la sensibilidad a la parametrización es alta y refuerza la necesidad de reportar el proceso completo y no solo el mejor punto.

4.4 Resultados finales y cumplimiento de umbrales

Depto.	Modelo final	RMSE	MAE	R ² LOYO	Mejora vs. baseline	Error como % del rendimiento medio
Nariño	ExtraTrees (parametrizado)	100,1	86,1	0,114	+13,7 %	9,4 % (RMSE); 8,1 % (MAE)
Quindío	Random Forest (parametrizado)	90,5	70,4	0,326	+24,7 %	8,2 % (RMSE); 6,4 % (MAE)
—	Umbral D3 (Fase 1)	≤ 186	≤ 149	≥ 0,50	—	—
—	Baseline (media histórica)	116,0 / 120,2	87,5 / 98,5	-0,19	0 %	—

Rendimiento observado vs. estimado mediante LOYO




Figura 3. Rendimiento observado y estimado mediante validación Leave-One-Year-Out (LOYO) para los modelos finales parametrizados en Nariño y Quindío.

La línea continua representa el rendimiento observado en el panel EVA-MADR y la línea discontinua las predicciones obtenidas dejando cada año fuera del entrenamiento. Fuente: elaboración propia.

La comparación año a año muestra que ambos modelos reproducen razonablemente la trayectoria general del rendimiento, aunque presentan mayor dificultad frente a cambios abruptos. En Nariño, los mayores desvíos se observan principalmente al inicio de la serie y alrededor de 2011–2013, mientras que en Quindío destaca la subestimación del choque observado en 2012. En los años más recientes las predicciones se aproximan con mayor claridad a los valores observados. Estos patrones son coherentes con las métricas LOYO reportadas: RMSE de 100,1 kg/ha y R^2 de 0,114 en Nariño, y RMSE de 90,5 kg/ha y R^2 de 0,326 en Quindío.

Nota metodológica sobre el umbral de error. El umbral de referencia $RMSE \leq 186$ kg/ha se mantuvo para preservar la consistencia metodológica con el Entregable 1, donde fue definido como aproximadamente el 15 % del rango histórico de rendimientos (760–2000 kg/ha) reportado por DANE–ENA. En esta fase, el modelo se entrenó sobre el panel consolidado EVA–MADR (2007–2018), cuyo rango observado fue de 854,05 a 1298,95 kg/ha (rango de 444,90 kg/ha). En consecuencia, el umbral de 186 kg/ha ya no representa el 15 % del rango del panel definitivo, sino un criterio de comparación heredado entre fases del proyecto.

Lectura de negocio: el scoring reduce el error del año normal en cerca del 14 % en Nariño y del 25 % en Quindío, con errores medios de 86 y 70 kg/ha, equivalentes aproximadamente al 6–9 % del rendimiento medio departamental. Los resultados se comparan frente al umbral metodológico heredado del Entregable 1 ($RMSE \leq 186$ kg/ha), manteniendo así la consistencia entre fases del proyecto. El R^2 LOYO de 0,114 y 0,326 se reporta como diagnóstico del desempeño predictivo sobre un panel productivo de 12 años; en Nariño, superar la referencia de la media histórica año a año constituye una mejora moderada, mientras que en Quindío la mejora es más consistente.

4.5 GAM exploratorio (requerimiento D1)

El GAM comprometido en la Fase 1 —curvas de respuesta de SPI-3, temperatura máxima y NDVI— se ajustó sobre las observaciones con información satelital real (2012–2018: 14 observaciones, 7 por departamento), la única ventana donde el NDVI existe sin interpolación:

Modelo	pseudo- R^2	AIC	Detalle
GAM con SPI-3 + Tmax + NDVI	0,225	Reportado en el notebook	Ningún término suave significativo ($p < 0,05$); intervalos de confianza amplios
GAM + departamento como efecto categórico	0,170	Mayor	El efecto departamental no mejora la explicación
Validación LOYO del GAM (14 obs)	$R^2 -2,73$	—	RMSE 176,0 kg/ha; MAE 138,4. Muy inferior a los modelos de árboles




Figura 4. Curva parcial del GAM para el SPI-3 medio, con intervalo de confianza. La amplitud del intervalo y la ausencia de curvatura significativa sustentan la declaración del GAM como herramienta exploratoria.

Lectura e interpretación: con 14 observaciones, el GAM no tiene potencia para estimar curvas suaves. La curva parcial de temperatura máxima muestra una tendencia decreciente, pero con intervalos amplios y con la separación de rangos entre departamentos —Nariño alrededor de 20 °C, Quindío entre 30 y 31 °C— confundiendo el efecto. Por eso el GAM se conserva como herramienta exploratoria de interpretación funcional y no como modelo predictivo: no hay evidencia estadística de términos no

lineales en la muestra disponible, y la no linealidad que sí existe en los datos —los árboles superan a los lineales entre 14 y 25 % de RMSE— es capturada por los modelos de ensamble. La declaración formal del ajuste del requerimiento D1 está en la sección 5.4.

5. Análisis de resultados, selección de alternativas y ajustes (Criterio 5)

5.1 Selección de modelos por requerimiento

La selección se hace por departamento, con evidencia LOYO completa, bajo seis criterios: RMSE, MAE, R², mejora frente al baseline, estabilidad del error y parsimonia.

Criterio	Nariño: ExtraTrees	Quindío: Random Forest	Nota
RMSE LOYO (kg/ha)	100,1 (mejor de 5)	90,5 (mejor de 5)	Ambos < 186
MAE LOYO (kg/ha)	86,1 (mejor)	70,4 (mejor)	Ambos < 149
R² LOYO (diagnóstico)	0,114 (mejor)	0,326 (mejor)	Por debajo del deseado 0,50
Mejora vs. baseline	+13,7 % (único que la supera)	+24,7 % (la mayor reducción)	Nariño: solo ExtraTrees supera la media histórica
Comportamiento tras tuning	Mejora (101,8 → 100,1)	Mejora (98,9 → 90,5)	XGBoost empeora en ambos tras parametrizar
Coherencia SHAP (Spearman vs. XGBoost)	0,886 (p = 0,019)	0,600 (p = 0,208)	Sección 5.2
Modelo único global	No viable	No viable	Las configuraciones ganadoras difieren por departamento

Modelos seleccionados para el scoring: ExtraTrees en Nariño y Random Forest en Quindío, ambos con la especificación fenológica de seis variables y parámetros elegidos por el proceso anidado. El XGBoost comprometido en la Fase 1 se conserva como modelo de contraste para interpretabilidad; la decisión de no usarlo como predictor se basa en su error LOYO sistemáticamente mayor y en la inestabilidad de su parametrización en muestras de 12 años. Su uso como motor de la justificación no exige que sea el predictor operativo, y la concordancia entre rankings es la evidencia de que la interpretación no depende del algoritmo elegido.

5.2 Interpretabilidad: SHAP sobre los modelos finales

Sobre los tres modelos de árboles se calcularon valores SHAP globales (Lundberg y Lee, 2017) para responder al requerimiento D2: identificar qué variables explican cada predicción y en qué orden. Los resultados para los modelos seleccionados:

Variable	Nariño · ExtraTrees (SHAP medio)	Quindío · Random Forest (SHAP medio)
Roya (indicador de epidemia)	36,99	44,38
SPI-3 floración	8,73	36,25
Temperatura máxima	7,47	3,93
ONI	6,86	5,02
SPI-3 cosecha	2,45	6,65
SPI-3 desarrollo	2,38	5,12
Concentración en las tres primeras	82,0 %	86,1 %




Figura 5. Importancia SHAP global de los modelos seleccionados, por departamento.

- **Concentración y jerarquía.** Las tres primeras variables concentran 82,0 % de la importancia SHAP en Nariño y 86,1 % en Quindío, por encima del umbral de 60 % fijado en D2. El SPI-3 de floración ocupa la segunda posición en ambos departamentos, lo que satisface el criterio de que una variable climática figure entre las tres principales y es coherente con la literatura agronómica: el amarre de la floración condiciona el número de granos que llegan a cosecha.
- **La jerarquía a partir de la tercera posición difiere entre departamentos, y esa diferencia es informativa.** En Nariño la temperatura máxima ocupa el tercer lugar y el ONI el cuarto, mientras que en Quindío el tercer lugar corresponde al SPI-3 de cosecha y la temperatura máxima queda en último lugar. Es consistente con los perfiles agroclimáticos de cada zona y refuerza la decisión de calibrar por departamento en lugar de ajustar un modelo único.
- **Coherencia entre algoritmos.** El ranking SHAP del modelo seleccionado correlaciona con el del XGBoost de contraste: Spearman de 0,886 ($p = 0,019$) en Nariño y 0,600 ($p = 0,208$) en Quindío. Las primeras posiciones son estables; la diferencia en Quindío se explica por el intercambio de posiciones menores. La interpretación no es un artefacto del algoritmo, y esto es lo que permite prometer la justificación de la señal al analista (N1).
- **El rol dominante de la roya.** El indicador del choque fitosanitario es la variable más importante en ambos departamentos, con una contribución media entre 1,2 y 4,2 veces la de la segunda variable. La sección siguiente cuantifica cuánto del desempeño del scoring depende de esa variable, porque determina lo que el modelo puede prometer en producción.

5.3 Sensibilidad al choque de roya (requerimiento D4)

Para evaluar la sensibilidad de los modelos a la variable `roya_dummy`, se reentrenaron las familias seleccionadas con y sin dicha variable, manteniendo el mismo esquema de validación Leave-One-Year-Out (LOYO).

Los hiperparámetros utilizados corresponden a la especificación definida para este experimento de sensibilidad y no a la parametrización anidada presentada en la Sección 4.4.

Depto.	Modelo	RMSE con roya	RMSE sin roya	Δ RMSE	R^2 con roya	R^2 sin roya
Nariño	ExtraTrees	100,1	124,0	+21,9 %	0,114	-0,360
Quindío	Random Forest	90,5	118,8	+20,2 %	0,326	-0,163
Quindío	ExtraTrees	96,5	115,4	+31,6 %	0,233	-0,097
Nariño	Random Forest	120,6	125,4	+7,7 %	-0,287	-0,391
—	Baseline	—	—	—	-0,19	-0,19

Nota. Los resultados corresponden al experimento de sensibilidad descrito en el bloque 21 del notebook, donde los modelos fueron evaluados con y sin la variable `roya_dummy` bajo validación LOYO. Estos resultados son independientes de la comparación de modelos optimizados presentada en la Sección 4.4.

- **Al retirar la variable `roya_dummy`, ningún modelo supera al baseline en Nariño:** (R^2 -0,36 y peor RMSE que la media histórica), y solo los de Quindío conservan parte de su ventaja, con un empate técnico frente al baseline. La ventaja predictiva de la especificación fenológica descansa, en proporción importante, en la señal fitosanitaria de la epidemia 2012–2014.

- **La estabilidad temporal comprometida (D4) no se cumple:** retirar la roya mueve el R^2 LOYO en aproximadamente 0,47 en Nariño y 0,49 en Quindío, muy por encima del umbral de 0,15. La Fase 1 ya preveía este confusor estructural —epidemia y renovación de cafetales— y pedía que se documentara como limitación; esta sensibilidad es esa documentación cuantitativa.
- **Implicación operativa para el scoring:** la variable de roya es ex post, pues identifica retrospectivamente 2012–2014, y un scoring prospectivo no puede asumirla conocida. Las opciones que esta fase deja planteadas, y que la Fase 3 debe resolver con el cliente, son: operar el scoring sin roya con su costo de error documentado; incorporar una fuente prospectiva del estado fitosanitario, como las alertas tempranas de la Federación; o acotar el uso del modelo con roya al diagnóstico retrospectivo. Es la decisión de diseño más importante que pasa a la Fase 3.

5.4 Ajustes implementados y declarados

Siguiendo el criterio 5 de la rúbrica, esta sección declara explícitamente qué se ajustó y por qué, distinguiendo ajustes de implementación, de datos, de esquema y de alcance:

#	Ajuste	Tipo	Justificación (evidencia)
1	Panel sin duplicados: 40 → 24 observaciones únicas	Datos	Auditoría: filas duplicadas por celda climática (3.1)
2	Exclusión de variables con fuga: producción, área cosechada, porcentaje de área cosechada y anomalía de temperatura	Datos / modelo	Relación mecánica o información futura respecto del rendimiento (3.1)
3	Eliminación de NDVI y EVI interpolados hacia atrás; panel satelital real 2012–2018	Datos	Valores constantes artificiales antes de 2012 (3.1)
4	Validación y corrección del SPI-3: estandarización y robustez de la agregación	Datos	Percentiles inconsistentes con un SPI en el desarrollo previo (3.2)
5	Selección de la especificación fenológica de seis variables	Modelo	Mejor equilibrio desempeño–parsimonia bajo LOYO (4.1)
6	Sustitución del hold-out de 4 observaciones por LOYO completo con parametrización anidada	Esquema experimental	Un hold-out de 4 puntos no da estimaciones estables; el LOYO evita fuga temporal (2.2)
7	Modelos por departamento en lugar de un modelo único	Esquema	Las familias y configuraciones ganadoras difieren entre departamentos (5.1)
8	XGBoost como contraste de interpretabilidad, no como predictor	Modelo	RMSE LOYO superior y parametrización inestable con $n = 12$ (5.1)
9	GAM declarado exploratorio (D1)	Alcance (declarado)	Sin términos significativos y R^2 LOYO de $-2,73$ con 14 observaciones (4.5)
10	R^2 reportado como diagnóstico interno del panel productivo	Alcance (declarado)	El tamaño del panel no permite leer el R^2 como evidencia de generalización
11	D4: no cumplimiento del umbral $ \Delta R^2 < 0,15$, declarado con sensibilidad completa	Alcance (declarado)	La roya es un confusor estructural; la Fase 3 define el mecanismo operativo (sección 6)
12	Umbral de la señal (N3) a recalibrar sobre el SPI-3 corregido	Alcance (declarado)	Los umbrales previos se basaron en un SPI no estandarizado (3.2)
13	Validación primaria de la señal contra anomalía de NDVI (D6) trasladada a la Fase 3	Alcance (declarado)	Requiere el panel espacial celda $\times$ compuesto, cuya construcción se calendariza en 6.1 (P4). La cobertura MODIS ya quedó auditada y corregida en esta fase

5.5 Limitaciones y criterios anticipados para la evaluación del prototipo

- **Tamaño del panel productivo (12 años por departamento).** Ningún método corrige por completo la incertidumbre de estimar con 12 puntos; el R^2 LOYO de Nariño y la sensibilidad al pliegue lo evidencian. Criterio de evaluación: el prototipo debe reportar en cada lectura el error esperado del año y no solo el punto estimado.

- **Dependencia de la señal fitosanitaria ex post.** Criterio: el prototipo debe declarar qué especificación opera, con o sin roya, y mostrar la lectura de exposición sin roya cuando corresponda, para no sobrepasar capacidad climática.
- **R² diagnóstico por debajo del rango deseado (0,11 y 0,33 frente a 0,50).** Criterio: la validación primaria de la señal no puede apoyarse solo en el panel productivo; la Fase 3 ejecuta la validación a nivel de celda contra la anomalía de NDVI, como se comprometió en D6.
- **La señal y sus pruebas (N1, N2, N4, D5) no existen aún como clasificación.** La Fase 3 las implementa sobre los umbrales recalibrados y los modelos seleccionados; los umbrales de aceptación ya están fijados en la sección 1.2.

5.6 Impacto esperado en las métricas de negocio

Las métricas técnicas de las secciones anteriores responden si el componente analítico funciona. Esta subsección responde una pregunta distinta: qué cambia en la operación de la aseguradora cuando el artefacto existe. Los seis indicadores se formulan en términos que un responsable de suscripción interpreta sin necesidad de conocer el modelo, y cada valor actual declara su origen.

#	KPI operativo	Valor actual	Valor deseado	Origen del valor actual
1	Costo de evaluación técnica del riesgo por póliza	\$511.000 (Quindío) · \$586.000 (Nariño)	\$34.100	Construcción por componentes
2	Tiempo de evaluación técnica del riesgo	1 día de campo por predio	1 hora de analista	Estimación profesional del equipo
3	Tiempo de respuesta al cliente en cotización	3 a 4 días hábiles	4 horas	Estimación profesional del equipo
4	Prima mínima viable para un pequeño productor	Piso determinado por el costo fijo de evaluación	Reducción del piso cercana al 90 %	Derivado del KPI 1
5	Fuentes consultadas manualmente por evaluación	4	0	Conteo directo
6	Consistencia de criterio entre analistas	No medida	Concordancia verificable	Hallazgo declarado

El KPI 1 es el determinante y explica por qué existe el seguro indexado. Su valor actual se construyó por componentes bajo el supuesto de que la aseguradora contrata peritos locales en cada departamento y que el recorrido requiere dos jornadas con una noche de alojamiento, dada la dispersión de los predios cafeteros. El costo del recorrido —honorarios, transporte, alimentación y alojamiento— asciende a \$1.770.000 en Quindío y \$2.070.000 en Nariño; prorrateado entre cuatro predios por recorrido y sumando dos horas de elaboración del informe, resulta en \$511.000 y \$586.000 por predio. El valor deseado corresponde a una hora de analista consultando el panel, calculada sobre un salario mensual de \$4.000.000 con factor prestacional de 1,5 y 176 horas laborales, esto es \$34.100. La reducción resultante es del 93 % y del 94 % respectivamente.

La conclusión no depende de la precisión de los supuestos sino de su orden de magnitud. Si el perito visitara seis predios por recorrido en lugar de cuatro, la reducción seguiría siendo del 91 %; con ocho predios, del 88 %. Un costo fijo de evaluación de medio millón de pesos por póliza no se sostiene contra la prima que puede pagar un predio de pocas hectáreas, y esa es precisamente la barrera que el artefacto elimina.

Precisión sobre el KPI 4. Una prima se compone de la prima de riesgo, que refleja la pérdida esperada, y de los recargos por gastos de operación, comercialización, evaluación y margen. El artefacto no modifica la prima de riesgo: la pérdida esperada por estrés climático en una zona es la que es. Lo que reduce es el componente de gastos, y específicamente el costo fijo de evaluación técnica que fija un piso por debajo del cual la póliza no puede venderse sin pérdida. Por esa razón el indicador se formula sobre la prima mínima viable y no sobre la prima total.

Origen de los valores y limitación declarada

Ninguno de los valores actuales proviene de datos operativos de una compañía aseguradora. El KPI 1 se construyó por componentes con supuestos explícitos; el KPI 5 es un conteo directo de las fuentes declaradas en el prototipo fachada; el KPI 6 registra la ausencia de instrumento de medición, que es en sí misma un hallazgo, porque una valoración que no se puede medir tampoco se puede auditar; y los KPI 2, 3 y 4 corresponden a estimación basada en la experiencia del equipo en el sector asegurador.

Esta limitación no invalida la comparación entre el escenario actual y el deseado, porque en el indicador donde el argumento depende de una magnitud se presenta el análisis de sensibilidad que muestra el rango en el que la conclusión se mantiene. La verificación de estos valores con una compañía aseguradora queda registrada como actividad de la Fase 3.

6. Componentes pendientes y plan hacia el prototipo funcional (Criterio 6)

La evaluación de completitud deja un diagnóstico claro: el componente analítico del scoring está implementado, validado y documentado; los componentes de producto —señal, interfaz, automatización y pruebas con usuarios— están pendientes y corresponden a la Fase 3. La fecha límite de la Fase 3 es el miércoles 23 de septiembre de 2026, lo que deja dos semanas y media de ejecución desde la fecha de este informe.

6.1 Componentes pendientes por implementar

#	Pendiente	Requerimiento	Detalle y decisión de diseño pendiente	Sem.	Riesgo si no se resuelve
P1	Recalibrar umbrales de la señal por departamento sobre el SPI-3 corregido	N3	Recalcular percentiles por ventana fenológica sobre la serie 2000–2024 y fijar la regla de clasificación	6	Señal con umbrales obsoletos
P2	Definir el mecanismo operativo de la roya en el scoring	D4, N2	Operar sin roya, incorporar fuente prospectiva o limitar el uso; definir la especificación que el prototipo expone	6	Sobreventa de la capacidad climática del panel
P3	Implementar la señal y sus pruebas	N1, N2, D5	Cruce de la clasificación con caídas bajo el P25; perturbación de $\pm 5\%$	6–7	N2 y D5 sin evidencia
P4	Validación primaria contra anomalía de NDVI a nivel de celda	D6	Panel espacial celda $\times$ compuesto MODIS; Spearman y recall sobre anomalías severas; excluir compuestos nublados	7	La señal queda sin validación independiente
P5	Integrar el scoring al prototipo funcional de una pantalla	F1–F4	Conectar Configurar – Observar – Valorar con predicción, SHAP del caso, error esperado y evidencia histórica	7	Entregable de producto incompleto
P6	Actualizar el pipeline del repositorio con las correcciones de la auditoría	F5, F6	Deduplicación, exclusión de variables con fuga, SPI-3 corregido, MODIS; regenerar y versionar datasets	7	Reproducibilidad y trazabilidad comprometidas
P7	Documentar cobertura y diferencias entre regiones en el manual	N5	Completitud del panel por variable y limitaciones de cobertura	8	N5 sin evidencia
P8	Pruebas con usuarios del perfil objetivo	N1, F1–F4	Demo guiada, cuestionario de 5 preguntas, 3 casos, tiempos de recorrido	8	N1 y F1–F4 sin resultado
P9	Actualizar la Tabla de Requerimientos con resultados de las pruebas	—	Diligenciar el formato oficial con el resultado de cada prueba prevista	8	Lista de chequeo sin cierre
P10	Alistamiento de entregables de la Fase 3	—	Repositorio versionado, manual de usuario, informe, acta de pruebas	8	Penalización de entrega
P11	Preparación de la presentación ejecutiva de 6 minutos	—	Problema, esquema de solución, entregables, propuesta de valor, costos y adopción	8	15 % de la nota en riesgo
P12	Mejora de modelos, si el cronograma lo permite	D1–D4	Re-estimar con datos EVA más recientes; evaluar especificación satelital completa	7–8	Mejora diferida sin afectar el MVP

6.2 Cronograma hacia la evaluación del prototipo (23 de septiembre)

Semana	Foco	Entregables parciales
Semana 6 (7–13 sep)	Cierre analítico: P1, P2, P3, P6	Umbrales recalibrados; decisión de roya; señal implementada y probada en datos; pipeline corregido y versionado
Semana 7 (14–20 sep)	Construcción del prototipo: P4, P5, P6	Validación NDVI a nivel de celda; scoring integrado al panel de una pantalla; datasets reproducibles

Semana	Foco	Entregables parciales
Semana 8 (21–23 sep)	Validación y alistamiento: P7–P11	Pruebas con usuarios y tabla diligenciada; manual; presentación ejecutiva; entrega del miércoles 23

La secuencia respeta las dependencias: la señal (P1) y su decisión de especificación (P2) preceden a la validación de negocio (P3); la validación de celda (P4) corre en paralelo a la integración (P5); y las pruebas con usuarios (P8) requieren el prototipo integrado. Los responsables se asignan por rol al inicio de la semana 6, y las decisiones P1 y P2 requieren una sesión con el cliente en la primera mitad de esa semana.

7. Conclusiones

- **La Fase 2 entrega un scoring auditado y corregido.** El desarrollo previo contenía problemas de fondo —duplicados, fuga de variables, SPI mal estandarizado y métricas de validación insuficientes— que invalidaban sus cifras. Tras la auditoría y los experimentos de esta fase, el panel, el índice y el proceso de validación quedan verificados y reproducibles desde el notebook.
- **La selección de modelos es por departamento y con evidencia temporal estricta:** ExtraTrees en Nariño (RMSE 100,1; R^2 0,114) y Random Forest en Quindío (RMSE 90,5; R^2 0,326), con la especificación fenológica de seis variables. Ambos cumplen los umbrales de error comprometidos y mejoran el baseline de la media histórica en 13,7 % y 24,7 %.
- **La interpretabilidad es estable y accionable:** las tres primeras variables concentran entre 82 y 86 % de la importancia SHAP, el SPI-3 de floración ocupa la segunda posición en ambos departamentos, y la concordancia con XGBoost sostiene la promesa de una señal explicable para el analista.
- **El límite del scoring climático quedó medido:** el desempeño depende en proporción importante de un indicador fitosanitario retrospectivo. Sin él, ningún modelo supera la media histórica en Nariño y en Quindío el empate es técnico. Es la limitación estructural más relevante y define la decisión de diseño P2 de la Fase 3.
- **El artefacto tiene un caso de negocio cuantificado:** la evaluación técnica del riesgo por póliza pasa de medio millón de pesos por predio a una hora de analista, una reducción del orden del 90 % que se sostiene incluso duplicando la productividad supuesta del peritaje. Es lo que convierte el producto en viable para el pequeño caficultor.
- **Los ajustes de alcance se declaran, no se ocultan:** GAM exploratorio por falta de potencia estadística, R^2 como diagnóstico interno del panel productivo, no cumplimiento del umbral de estabilidad D4 y traslado de la validación contra NDVI a la Fase 3, cada uno con su evidencia y su consecuencia.
- **El camino a la Fase 3 está trazado:** la señal, el prototipo de una pantalla y las pruebas con usuarios se calendarizaron hasta el 23 de septiembre, con las dependencias, los riesgos y los entregables identificados.

Referencias

- Avelino, J., Cristancho, M., Georgiou, S., Imbach, P., Aguilar, L., Bornemann, G., Läderach, P., Anzueto, F., Hruska, A. J. y Morales, C. (2015). The coffee rust crises in Colombia and Central America (2008–2013): impacts, plausible causes and proposed solutions. *Food Security*, 7(2), 303–321.
- Bergmeir, C. y Benítez, J. M. (2012). On the use of cross-validation for time series predictor evaluation. *Information Sciences*, 191, 192–213.
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
- Cawley, G. C. y Talbot, N. L. C. (2010). On over-fitting in model selection and subsequent selection bias in performance evaluation. *Journal of Machine Learning Research*, 11, 2079–2107.
- Comisión Económica para América Latina y el Caribe (CEPAL) y Deutsche Gesellschaft für Internationale Zusammenarbeit (GIZ) (2022). Seguros indexados para la agricultura: aspectos conceptuales, analíticos y de implementación. Documento de proyecto. Santiago de Chile: CEPAL.
- Geurts, P., Ernst, D. y Wehenkel, L. (2006). Extremely randomized trees. *Machine Learning*, 63(1), 3–42.
- Lundberg, S. M. y Lee, S.-I. (2017). A unified approach to interpreting model predictions. En *Advances in Neural Information Processing Systems* 30 (NeurIPS), 4765–4774.
- McKee, T. B., Doesken, N. J. y Kleist, J. (1993). The relationship of drought frequency and duration to time scales. En 8th Conference on Applied Climatology, 179–183. American Meteorological Society.
- Wood, S. N. (2017). *Generalized Additive Models: An Introduction with R* (2.^a ed.). Chapman & Hall/CRC.

Anexo A. Registro de actividades del notebook

La tabla siguiente reproduce el registro de actividades que el propio notebook mantiene, útil como índice de auditoría del proceso completo.

#	Sección	Actividad / hallazgo	Modelos	Resultado / decisión
1	1. Repositorio	Clonación del repositorio y localización de los archivos del desarrollo previo	—	Se audita el pipeline existente en lugar de reemplazarlo
2	2. ETL EVA	Recálculo del rendimiento como producción sobre área cosechada	—	Diferencias del orden de 10^{-13} : el objetivo está bien construido
3	3. Panel	Identificación de 40 filas con 24 combinaciones únicas departamento-año	—	Se depura a 24 observaciones únicas
4	4. Control de calidad	Cero faltantes tras la depuración	—	Sin imputaciones requeridas
5	5. MODIS	NDVI y EVI constantes antes de 2012 por interpolación hacia atrás	—	Exclusión del panel principal; panel satelital 2012–2018 de 14 obs
6	6. Fuga	Cuatro variables con relación mecánica o información futura	—	Sin variables mecánicas ni prospectivas en los predictores
7	7. SPI-3	Validación del índice: agregación simple frente a ponderada y propiedades estadísticas	—	Correlación 0,967 y 1,000; distribución estandarizada: índice válido
8	8–11	Construcción de especificaciones de variables	Ridge ($\alpha = 1$)	Selección de la especificación fenológica de 6 variables
9	12–14	Auditoría del modelado previo: hold-out de 4 observaciones; se adopta LOYO	5 familias + baseline	LOYO de 12 pliegues como esquema de validación
10	15	Comparación inicial de familias sobre la especificación fenológica	Ridge, Lasso, RF, ET, XGB	ExtraTrees lidera en ambos departamentos; Lasso descartado
11	16	Estabilidad del error: máximo y desviación por año	ET, RF, XGB	ExtraTrees con menor error máximo anual
12	17	Parametrización anidada con TimeSeriesSplit dentro de cada pliegue	ET, RF, XGB	Mejora selectiva: ET en Nariño y RF en Quindío
13	18	GAM exploratorio sobre SPI-3, Tmax y NDVI	GAM	pseudo- R^2 0,225; sin términos significativos; LOYO R^2 –2,73
14	19	SHAP global sobre modelos finales	ET, RF, XGB	Roya y SPI-3 de floración dominan; Spearman 0,886 y 0,600
15	20	Sensibilidad a la roya, con y sin la variable	ET, RF, XGB	Δ RMSE entre +7,7 % y +31,6 %; ΔR^2 entre 0,47 y 0,49
16	21	Discusión y decisiones	—	Modelos por departamento; D1 y D4 declarados; pendientes de Fase 3